

## Otimização da Observação Ambiental em Unidades de Conservação: Integração de Heurística e Programação Linear Inteira Mista

Luryan Delevati Dorneles, Ícaro Bezerra Queiroz de Araujo, Glauber Rodrigues Leite,  
Rian Gabriel Santos Pinheiro, Bruno Costa e Silva Nogueira

Universidade Federal de Alagoas

Av. Lourival Melo Mota, S/n — Tabuleiro do Martins, Maceió — AL  
lidd@ic.ufal.br, icaro@ic.ufal.br, glauber@ic.ufal.br,  
rian@ic.ufal.br, bruno@ic.ufal.br

### Resumo

Este artigo apresenta uma abordagem híbrida para otimizar a cobertura de imagens ópticas em Unidades de Conservação (UCs) brasileiras. A metodologia combina uma heurística gulosa, seguida de um modelo Programação Linear Inteira Mista (PLIM). O objetivo consiste em maximizar a cobertura útil qualificada das áreas monitoradas, considerando cobertura de nuvens, pixels válidos, compatibilidade orbital e consistência temporal para análise sequencial de uma mesma região. O modelo PLIM incorpora penalizações específicas para cobertura de nuvens e restrições de exclusividade de imagens, enquanto garante sobreposição adequada entre mosaicos selecionados. Os resultados demonstram que a abordagem PLIM resultou em redução média de 96,2% em relação à heurística gulosa inicial, mantendo a cobertura de nuvens controlada (abaixo de 10% em cenários favoráveis e não excedendo 23,68% em regiões tradicionalmente nebulosas), enquanto assegura cobertura geográfica das áreas estudadas.

**Palavras-chave:** Otimização Combinatória. Programação Linear Inteira Mista. Heurística gulosa. Sensoriamento Remoto.

**Eixo Temático:** AG&MA — PO na Agricultura, Meio Ambiente e Sustentabilidade.

**Abstract:** This paper presents a hybrid approach to optimize the coverage of optical images in Brazilian Conservation Units (UCs). The methodology combines a greedy constructive heuristic with a composite evaluation function, followed by exact optimization via Mixed-Integer Linear Programming (MILP). The objective is to maximize the qualified useful coverage of the monitored areas, considering cloud cover, valid pixels, orbital compatibility, and temporal consistency for sequential analysis of the same region. The MILP model incorporates specific penalties for cloud cover and image exclusivity constraints, while ensuring adequate overlap between selected mosaics. Results demonstrate that the PLIM approach achieved a 96.2% average reduction in the number of products compared to the initial greedy heuristic, maintaining cloud cover controlled (below 10% in favorable scenarios and not exceeding 23.68% in traditionally cloudy regions), while ensuring geographic coverage of the studied areas.

**Keywords:** Combinatorial Optimization. Mixed-Integer Linear Programming. Greedy Constructive Heuristic. Remote Sensing.

**Thematic area:** AG&MA — OR in Agriculture, Environment and Sustainability.

## 1 Introdução

O monitoramento de Unidades de Conservação (UCs) necessita de imagens ópticas de alta resolução. O programa Copernicus, através dos satélites Sentinel-2, proporciona um recurso valioso com imagens multiespectrais de até 10 metros de resolução e frequente revisita [Schuster et al., 2020]. Contudo, a cobertura de nuvens, a qualidade dos pixels e a sobreposição entre cenas prejudicam a consistência dos mosaicos [Rodríguez-Puerta et al., 2024].

A literatura apresenta diferentes variantes para o problema de mosaicos. Diversas abordagens buscam maximizar a área útil coberta, enquanto outras minimizam o número de mosaicos necessários. Alguns métodos penalizam imagens com maior presença de nuvens ou estabelecem limites mínimos de cobertura da área.

O método proposto maximiza a cobertura útil qualificada com penalização para presença de nuvens, visando identificar o subconjunto ótimo para áreas de conservação. A abordagem, validada com imagens Sentinel-2, aplica-se a diversos sensores ópticos que fornecem dados sobre cobertura de nuvens e qualidade de pixels. A função objetivo prioriza cobertura geográfica útil e qualidade, enquanto as restrições asseguram a sobreposição mínima entre mosaicos, cobertura mínima e exclusividade de imagens nos grupos.

Este trabalho propõe uma estratégia híbrida em duas etapas. Primeiro, uma heurística gulosa identifica grupos de mosaicos candidatos que satisfazem requisitos de cobertura de nuvens, pixels válidos e compatibilidade orbital e temporal. Em seguida, um modelo PLIM seleciona o subconjunto final que otimiza a função objetivo, respeitando todas as restrições. O objetivo final é alcançar mosaicos limpos o suficiente para uma análise espacial e temporal consistente ao longo de um período, permitindo o monitoramento efetivo das unidades de conservação, com a seleção de uma sequência de mosaicos que apresentam uma área de cobertura em comum ao longo do tempo. As principais contribuições incluem: (i) a heurística gulosa que pré-seleciona grupos de mosaicos; (ii) o modelo PLIM que garante consistência entre mosaicos sequenciais, e (iii) a validação da abordagem híbrida em diversas UCs brasileiras.

O restante deste artigo está organizado da seguinte forma: a Seção 2 apresenta a revisão de literatura relacionada ao problema de seleção de imagens e mosaicos. A Seção 3 detalha a metodologia proposta, incluindo a heurística gulosa (Fase 1) e o modelo PLIM (Fase 2). A Seção 4 apresenta e discute os resultados obtidos nas diferentes unidades de conservação brasileiras, incluindo análises comparativas entre a abordagem heurística e o modelo PLIM, além de exemplos visuais dos mosaicos gerados. Por fim, a Seção 5 apresenta as conclusões e direções para trabalhos futuros.

## 2 Revisão de Literatura

A composição de mosaicos ópticos para monitoramento ambiental enfrenta desafios como cobertura de nuvens, qualidade radiométrica dos pixels e inconsistências de sobreposição entre cenas. Métodos heurísticos predominavam inicialmente, com combinação de detecção de nuvens e técnicas de composição temporal para a geração de produtos livres de nuvens [Kempeneers e Soille, 2017].

Para formalizar matematicamente a seleção de imagens, a literatura recorre ao problema do *minimum axis-parallel rectangle cover of a rectilinear polygon without holes*, classificado como NP-difícil [Kumar e Ramesh, 1995; Masek, 1978]. Esta complexidade implica em esforço computacional

exponencial para soluções exatas diretas em grandes conjuntos de imagens.

Na evolução dos modelos exatos, Combarro Simón et al. [2023a] propuseram dois modelos baseado em *Constraint Programming* (CP) e outro em PLIM, testados em instâncias realistas de até 200 imagens. Os resultados comprovaram a viabilidade do PLIM aplicado diretamente ao conjunto total de polígonos gerados pela discretização geométrica. A metodologia apresentada por esses autores inclui apenas o pré-processamento por interseção de polígonos e a incorporação de nuvens como elementos do universo de cobertura, sem fases heurísticas ou penalizações arbitrárias.

Combarro Simón et al. [2023b] formalizaram o *Satellite Image Mosaic Combination Problem* (SIMCOP), com definição matemática como um problema de cobertura geométrica ponderada e aplicação em cenários reais com imagens Pleiades que cobrem aproximadamente 1640 km<sup>2</sup> na Cidade do México. Os autores propuseram uma heurística gulosa para a seleção de imagens baseada na razão entre área útil dentro da região de interesse e área total da imagem, com resultados 32,74% melhores que seleções aleatórias. Diferentemente da abordagem proposta no presente trabalho, o SIMCOP utiliza apenas uma heurística gulosa sem a etapa subsequente de otimização, não incorpora restrições de exclusividade de imagens e não considera principalmente explicitamente janelas temporais ou penalizações por cobertura de nuvens na função objetivo.

A literatura apresenta estratégias específicas para mosaicos com imagens Sentinel-2. Shepherd et al. [2020] propuseram método automático para a Nova Zelândia que aprimora o algoritmo Tmask na detecção de nuvens com pontuação paramétrica por pixel para compósitos sazonais de cinco verões consecutivos. Os mosaicos, baseados em aproximadamente 100 aquisições, obtiveram menos de 0,1% de cobertura residual de nuvens. A abordagem prioriza qualidade radiométrica sem utilizar otimização combinatória com restrições temporais ou exclusividade de imagens, complementando modelos exatos de seleção por CP e PLIM [Combarro Simón et al., 2023a] através de critérios espectrais refinados.

Em conservação ambiental, Beyer et al. [2016] aplicaram PLIM para priorização espacial com resultados superiores aos métodos heurísticos. Schuster et al. [2020] confirmaram a vantagem de solucionadores exatos de PLIM sobre *simulated annealing*. Rodríguez-Puerta et al. [2024] identificaram ruídos radiométricos em mosaicos Sentinel-2, problemas abordados no presente modelo via penalizações na função objetivo.

Em síntese, a literatura evidencia uma evolução de métodos heurísticos para modelos exatos e abordagens híbridas. A metodologia proposta apresenta uma abordagem em duas fases — heurística gulosa (incluindo uma etapa de pós-processamento) seguida do PLIM — para seleção de mosaicos em UCs brasileiras.

### 3 Metodologia Proposta

A metodologia desenvolvida para otimizar a seleção de imagens Sentinel-2 segue a abordagem híbrida em duas fases. A Tabela 1 define os principais parâmetros e variáveis utilizados. O método proposto é composto por duas fases, descritas a seguir:

A estratégia em duas fases contribui para a eficiência computacional e para a qualidade dos resultados. Sem o pré-processamento heurístico, a resolução direta via PLIM apresentaria dificuldades para conjuntos grandes de imagens, considerando a natureza NP-difícil do problema de cobertura. Modelar diretamente fatores de qualidade radiométrica, compatibilidade temporal e características

de cada imagem aumentaria o número de variáveis e restrições no PLIM, dificultando a resolução do problema para instâncias reais. A heurística gulosa filtra e agrupa imagens segundo critérios de efetividade, cobertura útil, qualidade radiométrica e compatibilidade temporal, reduzindo o espaço de busca para o modelo exato. Essa redução permite a resolução em tempo adequado e incorpora restrições operacionais difíceis de representar diretamente no PLIM. A estratégia híbrida combina aspectos metodológicos que favorecem soluções adequadas em termos de cobertura geográfica e consistência temporal para o problema de otimização de mosaicos para monitoramento ambiental.

- **Fase 1:** Gera um conjunto inicial mosaicos candidatos ( $M$ ), aplicando critérios de qualidade e compatibilidade para agrupar imagens Sentinel-2 (Seção 3.1).
- **Fase 2:** Seleciona o subconjunto ótimo de mosaicos a partir de  $M$ , utilizando o modelo PLIM (Seção 3.2).

Tabela 1: Variáveis e parâmetros do modelo de otimização

| Símbolo                                    | Descrição  |
|--|--|
| <b>Dados de Entrada</b>                    |  |
| $I$  | Conjunto de todas as imagens Sentinel-2 candidatas disponíveis                         |
| $A$  | Área de Interesse (UC)   |
| $t_i$                                      | Data de aquisição da imagem $i$  |
| $A_i$                                      | Cobertura geográfica da imagem $i$ sobre a área $A$                                    |
| $P_i$                                      | Proporção de pixels válidos na imagem $i$ dentro da área $A$                           |
| $N_i$                                      | Proporção da área $A$ coberta por nuvens na imagem $i$                                 |
| $\Delta T_{\max}$                          | Janela temporal máxima permitida entre imagens de um mosaico (5 dias)                  |
| $N_M^{\max}$                               | Limiar máximo de nuvens permitido em imagens (40%)                                     |
| <b>Fase 1: Heurística gulosa</b>           |  |
| $M_{\text{novo}}$                          | Mosaico em construção durante a execução da heurística                                 |
| $I_{\text{comp}}$                          | Conjunto temporário de imagens compatíveis durante construção do mosaico               |
| $A_i^{\text{eff}}$                         | Cobertura efetiva da imagem $i$ ( $A_i \times P_i$ )                                   |
| $Q_i$                                      | Fator de qualidade da imagem $i$ ( $(1 - N_i) \times P_i$ )                            |
| $E_i$                                      | Efetividade da imagem $i$ para seleção heurística ( $A_i^{\text{eff}} \times Q_i$ )    |
| $\Delta A^{\min}$                          | Incremento mínimo de cobertura para novas imagens no mosaico (5%)                      |
| $A_M^{\text{alvo}}$                        | Cobertura alvo para considerar um mosaico completo (85%)                               |
| $A_M^{\min}$                               | Cobertura mínima exigida para um mosaico ser considerado viável (2%)                   |
| <b>Saída da Fase 1 / Entrada da Fase 2</b> |  |
| $M$  | Conjunto de todos os mosaicos candidatos gerados na Fase 1                             |
| $I(j)$                                     | Conjunto de imagens que compõem o mosaico $j$  |
| $A_j$                                      | Área de cobertura do mosaico $j$ sobre a área de interesse $A$                         |
| $Q_j$                                      | Fator de qualidade médio do mosaico $j$  |
| $N_j$                                      | Máxima cobertura de nuvens entre as imagens do mosaico $j$ ( $\max_{i \in I(j)} N_i$ ) |
| <b>Fase 2: Modelo PLIM</b>                 |  |
| $I'$                                       | Conjunto de imagens elegíveis para restrição de exclusividade                          |
| $M(i)$                                     | Conjunto de mosaicos que contêm a imagem $i$   |
| $E_j$                                      | Cobertura efetiva total do mosaico $j$   |
| $\gamma$                                   | Peso de penalização para a cobertura máxima de nuvens                                  |
| $I_{j,k}$                                  | Indicador de sobreposição entre os mosaicos $j$ e $k$ sobre a área de interesse $A$    |
| $\theta$                                   | Limiar mínimo de sobreposição para seleção conjunta de mosaicos                        |
| $N_{\max}$                                 | Número máximo de mosaicos permitidos na solução final                                  |
| $y_j$                                      | Variável de decisão binária: 1 se o mosaico $j$ é selecionado, 0 caso contrário        |

### 3.1 Fase 1: Heurística Gulosa

O Algoritmo 1 exibe o pseudocódigo da heurística principal. Ela inicia com a classificação das imagens candidatas e calcula a cobertura efetiva de cada imagem como o produto entre a área geográfica da imagem sobre o território de interesse e a proporção de pixels válidos. Pixels não válidos correspondem a regiões sem dados. Durante a formação dos grupos de mosaicos, imagens são incluídas desde que contribuam com pelo menos  $\Delta A^{\min}$  (5%) de cobertura adicional e atendam à compatibilidade temporal, enquanto a meta global de cobertura ( $A_M^{\text{alvo}}$ ) permanece em 85%.

Após a geração dos grupos candidatos pela heurística principal (Fase 1), o modelo PLIM utiliza o cálculo de sobreposição dois a dois entre mosaicos apenas para garantir que a seleção final não inclua mosaicos com sobreposição inferior ao limiar estabelecido. A cobertura apresentada nos resultados corresponde à área efetivamente coberta pelos mosaicos selecionados.

---

#### Algorithm 1 Heurística Gulosa para Grupos de Mosaico

---

**Entrada:**  $I, A, \Delta T_{\max}, \Delta A^{\min}, A_M^{\text{alvo}}, A_M^{\min}, N_M^{\max}$

**Saída:**  $M$  (conjunto de mosaicos candidatos)

```

1: Inicializar  $M \leftarrow \emptyset$ 
2: Filtrar  $I$  removendo imagens com cobertura de nuvens  $N_i > N_M^{\max}$ 
3: while há regiões de  $A$  não cobertas do
4:   Inicializar  $M_{\text{novo}} \leftarrow \emptyset$ 
5:   Para cada imagem  $i \in I$ : calcular  $E_i = A_i \cdot P_i \cdot Q_i$ 
6:   Selecionar  $i^* \in I \mid E_{i^*} = \max_{i \in I} E_i$ 
7:   Adicionar imagem  $i^*$  ao mosaico  $M_{\text{novo}}$ 
8:   Definir  $I_{\text{comp}} \leftarrow \{i \in I : |t_i - t_{i^*}| \leq \Delta T_{\max}\}$ 
9:   while  $I_{\text{comp}} \neq \emptyset$  e cobertura pode ser melhorada do
10:    Para cada imagem  $i \in I_{\text{comp}}$ : calcular  $E_i = A_i \cdot P_i \cdot Q_i$ 
11:    Selecionar  $i^* \in I_{\text{comp}} \mid E_{i^*} = \max_{i \in I_{\text{comp}}} E_i$  e atenda critérios de sobreposição
12:    if  $i^*$  aumenta a cobertura em pelo menos  $\Delta A^{\min}$  then
13:      Adicionar  $i^*$  ao mosaico  $M_{\text{novo}}$ 
14:      Atualizar  $I_{\text{comp}} \leftarrow \{i \in I_{\text{comp}} : |t_i - t_j| \leq \Delta T_{\max} \text{ para todo } j \in M_{\text{novo}}\}$ 
15:    else
16:       $I_{\text{comp}} \leftarrow \emptyset$ 
17:    end if
18:  end while
19:  if mosaico  $M_{\text{novo}}$  cobre mais de  $A_M^{\text{alvo}}$  da área  $A$  ou  $I_{\text{comp}} = \emptyset$  then
20:    if cobertura do  $M_{\text{novo}} \geq A_M^{\min}$  then
21:      Adicionar  $M_{\text{novo}}$  a  $M$ 
22:    end if
23:  end if
24: end while
25: return  $M$ 

```

---

O processo de seleção maximiza a cobertura efetiva e qualidade dos mosaicos que atendam às restrições de janela temporal e incremento mínimo de cobertura. Conforme as linhas 19-22 do Algoritmo 1, implementa-se flexibilização da meta de cobertura ( $A_M^{\text{alvo}} = 85\%$ ) quando não há

imagens compatíveis adicionais, aceitando mosaicos que atendam ao limiar mínimo ( $A_M^{\min} = 2\%$ ). Esta adaptação preserva janelas temporais valiosas que, mesmo com cobertura geográfica subótima, seriam perdidas em áreas com restrições orbitais ou condições atmosféricas adversas.

### 3.2 Fase 2: Modelo de Programação Linear Inteira Mista

O modelo proposto para seleção ótima de grupos de mosaicos é apresentado abaixo:

$$\max \sum_{j \in M} E_j \cdot y_j - \gamma \sum_{j \in M} N_j \cdot y_j \quad (1)$$

$$\text{s.a.} \quad \sum_{j \in M} y_j \leq N_{\max} \quad (2)$$

$$\sum_{j \in M(i)} y_j \leq 1 \quad \forall i \in I' \quad (3)$$

$$y_j + y_k \leq 1 \quad \forall j, k \in M, j < k \mid I_{j,k} < \theta \quad (4)$$

$$y_j \in \{0, 1\} \quad \forall j \in M \quad (5)$$

A função objetivo (1) busca maximizar a soma da cobertura útil e qualificada dos mosaicos selecionados, penalizando a presença de nuvens. O termo  $\gamma$  foi ajustado empiricamente para priorizar mosaicos com menor cobertura de nuvens. O modelo impõe restrições para limitar o número máximo de mosaicos ( $N_{\max}$ ), garantir que cada imagem seja utilizada em no máximo um mosaico e impedir a seleção conjunta de mosaicos com sobreposição inferior a  $\theta$ . Assim, o número de mosaicos é controlado diretamente pela restrição (2), enquanto a função objetivo prioriza a maximização da cobertura útil e a minimização da presença de nuvens.

**Termo 1 - Benefício da cobertura útil:**  $\sum_{j \in M} E_j \cdot y_j$

- Representa o valor total da cobertura útil e qualificada obtida pelos mosaicos selecionados.
- Quanto maior a cobertura ( $E_j$ ), maior o benefício.

**Termo 2 - Penalização por nuvens:**  $\gamma \sum_{j \in M} N_j \cdot y_j$

- Penaliza a presença de nuvens, proporcional à máxima cobertura de nuvens ( $N_j$ ) no mosaico.
- O parâmetro  $\gamma$  atribui peso a esta penalização.

O modelo PLIM incorpora quatro restrições que garantem a qualidade e viabilidade das soluções. A restrição (2) estabelece um limite superior para o número de mosaicos selecionados, esta limitação é para evitar a fragmentação excessiva do monitoramento em múltiplos mosaicos, o que dificultaria análises temporais consistentes.

As restrições (3) implementam o princípio de exclusividade das imagens, onde  $I'$  representa o conjunto de todas as imagens presentes em pelo menos um mosaico candidato gerado na Fase 1. Esta condição assegura que cada imagem pertença a no máximo um mosaico selecionado, o que elimina redundâncias desnecessárias na solução final e otimiza a consistência radiométrica entre produtos temporais adjacentes.

A restrição (4) impede que dois mosaicos com sobreposição inferior a  $\theta$  sejam selecionados juntos. Esta restrição serve para garantir que os mosaicos selecionados cubram áreas suficientemente



similares, permitindo análises temporais sobre a mesma região. O limiar  $\theta$  foi ajustado para 80%, assegurando que qualquer sequência de mosaicos escolhida mantenha continuidade espacial suficiente para monitoramento efetivo. Na implementação, o indicador de sobreposição  $I_{j,k}$  é calculado como o valor mínimo entre as coberturas dos mosaicos envolvidos, ou seja,  $I_{j,k} = \min(A_j, A_k)$ , o que representa a interseção conservadora entre as áreas cobertas pelos mosaicos.

O modelo se completa com as restrições (5), que definem o caráter binário das variáveis de decisão. Cada mosaico deve ser integralmente incluído ou excluído da solução final, mantendo a consistência dos mosaicos resultantes.

## 4 Resultados Experimentais

Para validação, a metodologia foi aplicada em 13 Unidades de Conservação (UCs) e estâncias ambientais em 9 estados brasileiros, com extensões territoriais entre 3.708 ha (APA Catolé) e 1.019.460 ha (APA Chapada do Araripe). O estudo utilizou 1.941 imagens Sentinel-2 candidatas, adquiridas entre junho/2024 e abril/2025, das quais 524 atenderam aos filtros de qualidade e cobertura mínima estabelecidos. Os parâmetros experimentais incluíram cobertura mínima de 2%, janela temporal máxima de 5 dias e limiar de nuvens de 40%. O modelo PLIM foi resolvido usando CPLEX em ambiente Linux (Ubuntu 22.04) com processador Intel Xeon 3.4 GHz e 16 GB de memória.

A Tabela 2 apresenta os resultados da heurística gulosa por região. As colunas mostram: UF; nome da UC; área em hectares; total de imagens Sentinel-2 disponíveis; imagens aprovadas pelos filtros de qualidade; número de mosaicos candidatos gerados; e máxima cobertura de nuvens (%) nos mosaicos. Destaca-se a variação significativa de áreas territoriais e condições climáticas entre as regiões estudadas.

Tabela 2: Resultados iniciais da heurística Gulosa por região.

| UF       | UC                   | Área<br>(ha) | Imagens<br>(total) | Imagens<br>(aceitas) | Mosaicos<br>H. Gulosa | Nuvens<br>máx. (%) |
|----------|----------------------|--------------|--------------------|----------------------|-----------------------|--------------------|
| MG-SP-RJ | PARNA Mantiqueira    | 437.192      | 445                | 179                  | 45                    | 37,83              |
| RS       | APA Ibirapuitã       | 318.767      | 333                | 54                   | 16                    | 10,77              |
| MT       | PARNA do Pantanal    | 33.800       | 52                 | 52                   | 18                    | 9,12               |
| AL       | APA Muricy           | 129.742      | 310                | 80                   | 24                    | 38,91              |
|          | APA Santa Rita       | 9.633        |                    |                      |                       |                    |
|          | APA Catolé           | 3.708        |                    |                      |                       |                    |
|          | APA Pratagy          | 20.873       |                    |                      |                       |                    |
| BA       | PARNA Pau Brasil     | 18.934       | 154                | 37                   | 9                     | 38,68              |
|          | PARNA Monte Pascoal  | 22.239       |                    |                      |                       |                    |
|          | PARNA Descobrimento  | 22.607       |                    |                      |                       |                    |
|          | REVIS Rio dos Frades | 907          |                    |                      |                       |                    |
| PI-PE-CE | APA Chap. do Araripe | 1.019.460    | 641                | 106                  | 46                    | 26,77              |
|          | FLONA Araripe-Apodi  | 38.920       |                    |                      |                       |                    |

A distribuição temporal dos mosaicos refletiu limitações climáticas específicas de cada região: na APA Ibirapuitã (RS), condições de nebulosidade resultaram em 16 mosaicos selecionados pela heurística gulosa com cobertura máxima de nuvens de 10,77%, enquanto no PARNA Mantiqueira, a maior disponibilidade de imagens permitiu a geração de 45 grupos com presença de nuvens de até 37,83%.

A Tabela 3 apresenta o refinamento obtido pela otimização PLIM em comparação com a heurística inicial. As colunas mostram: a unidade federativa (UF); a quantidade de mosaicos selecionados; a quantidade de imagens contidas em cada mosaico; os IDs dos mosaicos selecionados pelo modelo; e as unidades de conservação correspondentes. Os resultados demonstram uma significativa redução no número de grupos selecionados, com o modelo elegendo entre 4 e 6 mosaicos por região, mantendo cobertura total acima de 89% em todas as áreas estudadas.

Tabela 3: Resultados da otimização CPLEX por região.

| UF       | Qtd. de mosaicos | Qtd. de imagens por mosaico | IDs dos mosaicos       | Unidades de Conservação   |
|----------|------------------|-----------------------------|------------------------|---|
| BA       | 5                | 1                           | 1, 2, 3, 5, 6          | PARNAs Pau Brasil, Monte Pascoal, Descobrimento, REVIS Rio dos Frades |
| AL       | 4                | 2                           | 1, 2, 3, 5             | APAs Muricy, Santa Rita, Catolé, Pratygy                              |
| RS       | 5                | 1–2                         | 1, 2, 3, 6, 9          | APA Ibirapuitã  |
| MG-SP-RJ | 6                | 2                           | 13, 14, 15, 16, 17, 20 | PARNA Mantiqueira   |
| PI-PE-CE | 6                | 3                           | 9, 10, 11, 13, 31, 33  | APA Chapada do Araripe, FLONA Araripe-Apodi                           |
| MT       | 6                | 1–2                         | 1, 2, 3, 4, 5, 6       | PARNA do Pantanal   |

A Figura 1 ilustra os mosaicos ótimos selecionados para a região de MT (PARNA do Pantanal), evidenciando que todos os mosaicos finais estão livres de nuvens, conforme os parâmetros do modelo.

A visualização permite observar a configuração espacial dos mosaicos ótimos, destacando que o modelo priorizou imagens com maior efetividade ( $E_j$ ) e ausência de nuvens, conforme a função objetivo (1). As imagens exibidas correspondem diretamente aos mosaicos listados na Tabela 3, refletindo a solução final otimizada para a área de interesse. Eventuais variações de qualidade radiométrica ou pequenas lacunas de cobertura são resultado das restrições climáticas e geométricas, mas o método garantiu cobertura útil e controle total de nuvens para MT.



Figura 1: Sequência de mosaicos selecionados pelo CPLEX para a região de MT (PARNA do Pantanal). As imagens mostram os mosaicos escolhidos pelo modelo conforme listados na Tabela 3, todos livres de nuvens, apresentando uma sequência temporal com sobreposição espacial acima de 80% e características radiométricas adequadas para análise temporal da área de conservação.

A Tabela 4 apresenta, para cada região, a cobertura real obtida após o pós-processamento, o maior percentual de nuvens e o menor fator de qualidade entre os mosaicos selecionados pelo modelo



CPLEX. Estes valores representam, respectivamente, os cenários mais desafiadores de cada região quanto à presença de nuvens e à qualidade radiométrica.

Tabela 4: Cobertura real, maior percentual de nuvens e menor fator de qualidade entre os mosaicos selecionados pelo modelo CPLEX para cada região.

| UF       | UC                   | Cobertura (%) | Nuvens (%) | Fator Qualidade (%) |
|----------|----------------------|---------------|------------|---------------------|
| BA       | PARNA Pau Brasil     | 100,00        | 18,44      | 74,65               |
| AL       | APA Muricy           | 100,00        | 21,55      | 75,09               |
| RS       | APA Ibirapuitã       | 98,93         | 3,36       | 73,08               |
| MG-SP-RJ | PARNA Mantiqueira    | 89,14         | 1,86       | 94,33               |
| PI-PE-CE | APA Chap. do Araripe | 92,52         | 3,26       | 98,58               |
| MT       | PARNA do Pantanal    | 100,00        | 0,00       | 99,90               |

A análise detalhada mostra uma significativa redução nos mosaicos candidatos, com o modelo PLIM selecionando de 4 a 6 mosaicos por região, em contraste com o conjunto mais amplo sugerido pela heurística gulosa inicial. Esta otimização demonstra a eficácia do modelo em identificar os mosaicos com melhor relação entre cobertura útil e qualidade radiométrica para cada área de interesse, mantendo a sobreposição mínima de 80% entre os mosaicos selecionados. Isto garante a consistência espacial necessária para análises temporais robustas.

Destaca-se a região PI-PE-CE, onde o modelo reduziu de 46 mosaicos candidatos para 6 (incluindo os mosaicos 9, 10, 11, 13, 31 e 33), e o PARNA Mantiqueira na região MG-SP-RJ, com redução de 45 para 6 mosaicos selecionados (incluindo os mosaicos 13-17 e 20). A BA apresentou o menor número de imagens por mosaico selecionado (apenas uma), enquanto PI-PE-CE teve três imagens em cada mosaico selecionado, o que reflete as diferentes complexidades geométricas e condições de imageamento das regiões.

A análise quantitativa demonstra que a metodologia alcançou excelentes resultados de áreas livres de nuvens nos mosaicos finais, com média superior a 98% (considerando a ponderação por área), e variações conforme as condições climáticas regionais (de 98,93% na APA Ibirapuitã a 78,45% nas APAs de Alagoas). A Figura 2 apresenta a visualização espacial de todos os mosaicos selecionados pelo modelo CPLEX para cada região. Esta visualização mostra como a abordagem proposta selecionou sequências de mosaicos que mantêm consistência espacial ao longo do tempo, permitindo a análise temporal das áreas monitoradas.

Comparações diretas com trabalhos anteriores apresentam limitações metodológicas substanciais devido às diferenças fundamentais de objetivos: enquanto Rodríguez-Puerta et al. [2024] concentraram-se exclusivamente na remoção de nuvens (atingindo 89,4% de eficácia com CloudScore<sup>+</sup>) e Shepherd et al. [2020] priorizaram qualidade radiométrica em mosaicos sazonais de verão na Nova Zelândia (com nuvens residuais <0,1%), a presente metodologia integra otimização multidimensional que contempla simultaneamente cobertura útil, qualidade radiométrica e sequências temporais consistentes, associando heurística gulosa com PLIM para garantir exclusividade de imagens e eficiência computacional em monitoramento contínuo de áreas geograficamente diversas.




Figura 2: Visualização de todos os mosaicos selecionados pelo modelo CPLEX para cada região. As áreas aparecem reduzidas devido à sobreposição e escala, servindo apenas para referência geral da distribuição espacial das soluções.

## 5 Conclusão

Os mosaicos selecionados pelo modelo PLIM atingiram fatores de qualidade satisfatórios, com redução média de 96,2% em relação à heurística gulosa inicial, selecionando entre 4 e 6 mosaicos por região. O controle da cobertura de nuvens foi eficaz, mantida abaixo de 10% em cenários favoráveis como APA Ibirapuitã (3,36%) e em níveis aceitáveis mesmo em regiões tradicionalmente nebulosas como a APA Muricy (21,55%). A diversidade das UCs estudadas, de 3.708 ha a mais de 1 milhão de hectares, demonstra a aplicabilidade da metodologia em diferentes contextos geográficos e climáticos.

A abordagem híbrida desenvolvida, com suas etapas distintas — heurística gulosa (Fase 1) e otimização PLIM (Fase 2) — mostrou-se efetiva para obter soluções de qualidade. O algoritmo PLIM garante que os mosaicos selecionados mantenham sobreposição espacial de pelo menos 80%, permitindo análises temporais consistentes sobre as mesmas regiões ao longo do tempo.

A incorporação de penalizações específicas para cobertura de nuvens na função objetivo do modelo PLIM resultou em soluções otimizadas, com 202 imagens selecionadas no total. Mesmo nas áreas com maior complexidade geométrica, como a APA Chapada do Araripe e o PARNA Mantiqueira, o método alcançou coberturas satisfatórias de 92,52% e 89,14%, respectivamente.

Embora o método assegure intervalos curtos entre imagens de um mesmo mosaico, o espaçamento entre mosaicos consecutivos pode variar devido às condições climáticas, refletindo limitações inerentes ao sensoriamento óptico.

Trabalhos futuros podem explorar recortes parciais e janelas temporais maiores para cobrir lacunas em áreas com alta nebulosidade, além de incorporar imagens SAR na função objetivo.

Pretende-se também expandir a aplicação para diferentes regiões e perfis climáticos, e investigar estratégias de fusão de imagens para manter a visualização global em períodos de disponibilidade limitada.

## Referências

- Beyer, H. L., Dujardin, Y., Watts, M. E., e Possingham, H. P. (2016). Solving conservation planning problems with integer linear programming. *Ecological Modelling*, 328:14–22. URL <https://doi.org/10.1016/j.ecolmodel.2016.02.005>.
- Combarro Simón, M., Danoy, G., Musial, J., Tchernykh, A., Alswaitti, M., Pecero, J., e Bouvry, P. (2023b). Satellite image mosaic combination problem. In *International Conference on Parallel Processing and Applied Mathematics (PPAM)*, p. 1–3. URL <https://orbilu.uni.lu/handle/10993/59378>. Extended abstract.
- Combarro Simón, M., Talbot, P., Danoy, G., Musial, J., Alswaitti, M., e Bouvry, P. (2023a). Constraint model for the satellite image mosaic selection problem. In *29th International Conference on Principles and Practice of Constraint Programming (CP 2023)*, volume 280 of *Leibniz International Proceedings in Informatics (LIPIcs)*, p. 44:1–44:15. URL [https://cs.emis.de/LIPIcs/volltexte/2023/19081/pdf/LIPIcs-CP-2023-44\\_.pdf](https://cs.emis.de/LIPIcs/volltexte/2023/19081/pdf/LIPIcs-CP-2023-44_.pdf).
- Kempeneers, P. e Soille, P. (2017). Optimizing sentinel-2 image selection in a big data context. *Big Earth Data*, 1(1–2):145–158. URL <https://doi.org/10.1080/20964471.2017.1407489>.
- Kumar, V. S. A. e Ramesh, H. (1995). Covering rectilinear polygons with axis-parallel rectangles. *SIAM Journal on Computing*, 24(3):636–650. URL <https://epubs.siam.org/doi/10.1137/S0097539799358835>.
- Masek, W. J. Some np-complete set covering problems. Unpublished manuscript, MIT, Cambridge, MA, 1978. Available via David Johnson’s NP-completeness column (<https://citeseerx.ist.psu.edu/document?doi=ec5d9f9c6e72ecf6fbc51ee5c14ceef0a0d596c2>), 1978.
- Rodríguez-Puerta, F., Perroy, R. L., Barrera, C., Price, J. P., e García-Pascual, B. (2024). Five-year evaluation of sentinel-2 cloud-free mosaic generation under varied cloud cover conditions in hawai’i. *Remote Sensing*, 16(24):4791. URL <https://doi.org/10.3390/rs16244791>.
- Schuster, R., Hanson, J. O., Strimas-Mackey, M., e Bennett, J. R. (2020). Exact integer linear programming solvers outperform simulated annealing for solving conservation planning problems. *PeerJ*, 8:e9258. URL <https://doi.org/10.7717/peerj.9258>.
- Shepherd, J. D., Schindler, J., e Dymond, J. R. (2020). Automated mosaicking of sentinel-2 satellite imagery. *Remote Sensing*, 12(22):3680. URL <https://doi.org/10.3390/rs12223680>.